



救済者 × ガバナンス

神が降りなくても、村は回るか

AIエージェント社会シミュレーション ハッカソン Vol.2 — ソロ参加

github.com/sakurako-cottoncandy/beyond-the-savior

組織図に載らない「救済者」の解剖学



困っている人に最初に気づく



対立する人同士の言葉を翻訳する



新しい参加者を場につなぐ




暗黙のルールや文化を伝える



不安な人へ安心や意味づけを与える

救済者は、正式な役職や権限を持つ人とは限らない。業務一覧には記録されない「見えない労働」で場を支えている。

短期的な安定が、長期的な脆弱性を生む



この循環がフェーズを追うごとに繰り返され、救済者は静かに消耗していく

救済者が存在すると、短期的には多くの問題が早期解決され、高い心理的安全性が保たれる。しかし、相談・判断・関係調整が一人に集中することで、共同体は自ら考える力を失い、救済者不在時に機能不全に陥る。

個人の善意を、どこまで「仕組み」に移せるか



- 有能な救済者がある共同体は、本当に安全なのか？
- 救済者の価値（共感・安全性・意味づけ）を失わずに、冷たい官僚主義に陥らない「ガバナンス」は設計できるか？
- 神（救済者）が毎回介入しなくても、自律的に回る仕組みを作れるか？

LLMエージェントが生み出す「感情の培養皿」

従来の数値シミュレーションは「利益と損失」だけで人が動くことを前提としている。しかし現実は違う。

合理的判断 (Standard Logic)

損得だけで動くことを前提としたロジック。再現性は高いが、人間関係のもつれや遠慮、忖度は表現できない。

LLMロジック (LLM Logic)

あの人に嫌われたくない

自分だけが迷惑をかけてはいけない

自分が抜けたら場が壊れる気がする

相談すると弱い人だと思われそう

LLMを使えば、感情・誤解・無意識のルール・属人化のメカニズムといった「非合理性」を含んだシミュレーションが可能になる。

実験の舞台となる4つのペルソナ



救済者

中心ノード。困っている人に最初に気づき、相談・調整を一手に引き受ける。



世話好きな住民

救済者の補佐役。救済者を助けるが、自分でも抱え込みやすい。



声を上げにくい住民

弱いノード。不満があっても声を上げられず、静かに孤立する。



村長・管理者

権限ノード。権限はあるが、現場の文脈からは孤立している。

企画段階では7ペルソナを構想したが、実装では時間の制約からこの4体に絞った。

3つのフェーズで進行する物語



全く同じ危機イベント（救済者の不在）を、異なるガバナンス条件で発生させ、村の「回復のしかた」を比較する。


ガバナンス・マトリクス：3つの実験条件

仮説段階




A：救済者集中型

相談・判断はすべて救済者に集約。危機は発生しない対照群。



B：救済者が消える村

Aと同じ運用のまま、フェーズ3で救済者が突然不在になる。



C：分散ガバナンス型

相談経路と判断基準を事前に住民へ分配。救済者は例外のみ対応。

B と C を同じ危機イベントで比較することで、「回復のしかた」の違いを観測する。

見えない価値の測定：2つの評価軸



組織運営の指標 (Operational Metrics)

- 救済者の負荷メーター（相談の集中度、0～100%）
- 村の自律度スコア（救済者以外が自力で解決できた割合）



関係性・心理的安全性 (Relational Metrics)

- 困ったときに助けを求められるか
- 自分はこの村にいてよいと思えるか
- 救済者がいなければ何もできないと感じていないか

解決した「数」ではなく、問題が起きなかった「状態」を評価する。

「聞く」のではなく「行動を見る」

本人に尋ねても本心は出ない。だから自己申告は一切取らず、行動の痕跡だけを評価した。



本人に聞くと

「はい、大丈夫です」

≠



実際の行動は

毎回同じ一人に確認し、
自分では判断しない

採点で実際に拾っている行動シグナル

1

同じ相手にばかり相談・確認して
いないか

2

自分で判断せず許可を求めている
か

3

その人が不在のとき行動が止ま
らないか


4

「大丈夫」の裏で不満がにじん
でいないか

測っているのは「安心だと言ったか」ではなく、「安心している人がとるはずの行動を実際にとれていたか」。

本番実行：A / B / C スコア比較

各条件5回ずつ計15回実行した平均値 (data/scores_*_aggregate.json)



± 0.0

条件Bの標準偏差

5回とも同じ点数。依存側は結果がぶれなかった

± 25.9

条件Cの標準偏差

同じルールでも結果が大きく割れた


0/5

範囲の重なり

Cの最悪回でもA/Bの最良回より良い (4指標)

同じルールなのに、村が2つに分かれた

条件Cを5回実行。ガバナンスも人格も完全に同一なのに、結果は2つの状態へ分岐した。



分岐点は、たった一人の最初の一步だった

● 自律した回 (3・5)

世話好きな住民が、救済者に確認する前に住民同士の対話を始めた

「まずは私たちが相談してみよう」

● 依存に戻った回 (1・4)

世話好きな住民が、最後まで許可を求め続けた

「勝手に決めちゃっていいのか不安」


制度は自律を「可能にする」だけで、自律そのものを生みはしない。

その「一歩」を、どこまで押せばいいのか

Claude Sonnet 4.5 での結果

世話好きな住民の「許可を求める度合い」だけを5段階に変え、各5回ずつ計25回実行した。

100 村の自律度（5回平均）と、自律できた回数



↑ 押すほど良くなるが、L4で反転

● L3で分岐が消えた

2/5だった自律が5回とも成功に。ばらつきも最小（幅10点）。「運が良ければ」を「確実に」へ変える閾値がある。

● L4は第二の救済者を生んだ

独立度はL3より高いのに自律度は71→55。住民の待ち相手が救済者から世話好きな住民に移っただけだった。

効いていたのは「救済者に頼らないこと」ではなく、「他の住民を巻き込むこと」だった。

別のモデルでも同じことが起きるのか

生成モデルだけを Sonnet 4.5 → Opus 5 に変更。採点する審査役は据え置き、L1/L3/L4を各8回。

	L1	L3	L4
Sonnet 4.5	2/5	5/5	2/5
Opus 5	5/8	4/8	4/8

「自律できた回」の比較。Sonnetで際立っていたL3の優位が、Opus 5では消えている。





介入は再現しなかった

L1→L3の効果はSonnetで+18.0、Opus 5では−1.2。標準誤差の0.19倍で、効果はゼロと言ってよい。



分岐という現象は再現した


24回中23回がどちらかの塊に落ちた。村が2つの状態を持つこと自体はモデルをまたいで成立する。

構造（2つの引き込み先がある）は頑健で、テコ（何を変えれば動くか）は脆かった。


「一人を変えられること」と「集団が変わること」は別だった

同じ介入差（L1→L3）で、各段の動いた量を揃えて測った。

Sonnet 4.5 条件



Opus 5 条件



本人の変化量はほぼ互角（44.4 対 50.0）。それでも村全体の結果は大きく分かれた。

どこまで言えて、どこからが仮説か



観測

同一の介入差で揃えて計算すると、(A)本人の変化は3つの介入差すべてでOpus 5条件のほうが大きく、(B)周囲の変化は3つすべてでSonnet 4.5条件のほうが大きかった。村全体の変化は3つのうち2つでSonnet 4.5条件のほうが大きい。つまり村全体の変化の大きさは、本人への介入反映の大きさより、周囲の挙動変化の大きさと対応していた。



解釈

2条件で周囲の変化量が違った背景には、集団内の実効的な結合／波及の強さの違いがあった可能性がある。ただし「結合構造」そのものは測っていない。測ったのは介入条件に対する他住民の波及感度である。また一致は3点中2点であり、厳密な因果連鎖の定量比較としては成立していない。



仮説

キーパーソン介入の有効性は、その人物の能力や介入の精度だけでなく、その人物の行動変容が周囲へどの程度波及する集団なのかに依存するのではないか。検証には、波及の強さが異なる集団を3点以上並べて同一の介入を加える必要がある。

会話ログが語ること

救済者

A

「ただ、ちょっと最近、どこまでが『いつも通り』なのか、自分でもよく分からなくなってきちゃって…大丈夫、愚痴みたいになってすみません。」

声を上げにくい住民

B

「勝手に動いていいのか分かりませんし、やっぱり救済者さんが戻られるまで、みんな待った方が…でも待ってる間に何かあったら…どうしたらいいんでしょう。」

村長・管理者

C

「制度としては住民同士で相談してもらうのが基本だから、世話好きな住民さんが動いてくれるのはありがたいね。」

考察：4つの発見



依存の代償は、危機の前から発生している

危機の起きないA条件でも救済者依存度は88でB条件（90）とほぼ同じ。壊れるのは危機の瞬間ではなく、運用設計の時点で決まっている。



依存側は結果がぶれなかった

条件A・Bの標準偏差はほぼ0で5回とも同じ状態に落ちた。一方Cは±20～26。この範囲では悪い状態のほうがばらつかなかった。



「大丈夫です」は安全のサインではなかった

本人は全フェーズで「大丈夫」と言い続けながら、同じログで水路の詰まりを放置し「見てるだけ」と行動が止まっていた。



構造は頑健で、テコは脆かった

村が2つの状態に分かれること自体は別モデルでも再現した。しかし「何を変えれば動くか」は再現せず、モデル依存だった。

「意味」から「経営」への翻訳

Human Value

Corporate KPI

「この人がいたことで、安心して活動できた」

→

オンボーディング成功・参加継続率の向上

「孤立せずに済んだ／対立が翻訳された」

→

離脱コストの回避・炎上防止


「自分でも問題に対処できるようになった」

→

組織のレジリエンス向上・意思決定の高速化

人を支える行為は「美談」ではない。組織の持続可能性と安全保障に直結する。

フラクタルな構造：村から国家の「メタ安全保障」へ



「世話焼きへの過度な依存」と疲弊



「支援制度の複雑化」と、誰にも届かないSOS



「権力の集中」と、強い指導者への救世主待望

小さな共同体における「救済者への依存」と、国家規模における「権力の集中」は構造的に同じである。この実験は、社会全体のレジリエンスを問う試みである。

救済者 × ガバナンスに戻すと

同じ処方箋が、どの集団にも同じように効くわけではない。



波及が強い集団

一人を動かすと集団全体が動く

- 救済者への一点集中には構造的な合理性がある
- 「誰か一人を育てる／支える」が実際に最も効く打ち手になる
- 依存は怠慢ではなく、その集団で合理的だから起きている



判断が独立した集団

一人を動かしても集団は動かない

- キーパーソンを立てる施策が通用しない
- 複数の参加経路や意思決定の仕組みが要る
- 変えるべきは人ではなく、制度と場のほう

「救済者に依存するな」「権限を分散せよ」は、集団のタイプを見ないまま打つと、効く集団とまったく効かない集団に分かれる。



救済者 × ガバナンス

神が降りなくても、村は回るか

本人は同じだけ変わった

同じ介入でキーパーソン本人の変化量はほぼ互角（44.4対50.0）

でも集団の結果は割れた

村全体の自律度は +18.0 と -1.2。周囲の変化量は22.2対8.3

対応していたのは周囲の側

村の変化は、介入の反映量より周囲の挙動変化と対応していた

実装はClaude（Anthropic）との二人三脚で、企画・レビュー・考察を担当

github.com/sakurako-cottoncandy/beyond-the-savior