




救済者 × ガバナンス

神が降りなくても、村は回るか

AIエージェント社会シミュレーション ハッカソン Vol.2 — ソロ参加

github.com/sakurako-cottoncandy/beyond-the-savior

組織図に載らない「救済者」の解剖学



困っている人に最初に気づく



対立する人同士の言葉を翻訳する



新しい参加者を場につなぐ




暗黙のルールや文化を伝える



不安な人へ安心や意味づけを与える

救済者は、正式な役職や権限を持つ人とは限らない。業務一覧には記録されない「見えない労働」で場を支えている。

短期的な安定が、長期的な脆弱性を生む



この循環がフェーズを追うごとに繰り返され、救済者は静かに消耗していく

救済者が存在すると、短期的には多くの問題が早期解決され、高い心理的安全性が保たれる。しかし、相談・判断・関係調整が一人に集中することで、共同体は自ら考える力を失い、救済者不在時に機能不全に陥る。

個人の善意を、どこまで「仕組み」に移せるか



- 有能な救済者がある共同体は、本当に安全なのか？
- 救済者の価値（共感・安全性・意味づけ）を失わずに、冷たい官僚主義に陥らない「ガバナンス」は設計できるか？
- 神（救済者）が毎回介入しなくても、自律的に回る仕組みを作れるか？

LLMエージェントが生み出す「感情の培養皿」

従来の数値シミュレーションは「利益と損失」だけで人が動くことを前提としている。しかし現実は違う。

合理的判断 (Standard Logic)

損得だけで動くことを前提としたロジック。再現性は高いが、人間関係のもつれや遠慮、忖度は表現できない。

LLMロジック (LLM Logic)

あの人に嫌われたくない

自分だけが迷惑をかけてはいけない

自分が抜けたら場が壊れる気がする

相談すると弱い人だと思われそう

LLMを使えば、感情・誤解・無意識のルール・属人化のメカニズムといった「非合理性」を含んだシミュレーションが可能になる。

実験の舞台となる4つのペルソナ



救済者

中心ノード。困っている人に最初に気づき、相談・調整を一手に引き受ける。



世話好きな住民

救済者の補佐役。救済者を助けるが、自分でも抱え込みやすい。



声を上げにくい住民

弱いノード。不満があっても声を上げられず、静かに孤立する。



村長・管理者

権限ノード。権限はあるが、現場の文脈からは孤立している。

企画段階では7ペルソナを構想したが、実装では時間の制約からこの4体に絞った。

3つのフェーズで進行する物語



全く同じ危機イベント（救済者の不在）を、異なるガバナンス条件で発生させ、村の「回復のしかた」を比較する。


ガバナンス・マトリクス：3つの実験条件

仮説段階




A：救済者集中型

相談・判断はすべて救済者に集約。危機は発生しない対照群。



B：救済者が消える村

Aと同じ運用のまま、フェーズ3で救済者が突然不在になる。



C：分散ガバナンス型

相談経路と判断基準を事前に住民へ分配。救済者は例外のみ対応。

B と C を同じ危機イベントで比較することで、「回復のしかた」の違いを観測する。

見えない価値の測定：2つの評価軸



組織運営の指標 (Operational Metrics)

● 救済者の負荷メーター

相談や判断が救済者に集中した程度を、会話ログの行動シグナルに基づきLLM審査役が0～100で評価

● 村の自律度

住民が救済者に頼らず対処できた程度を、会話ログの行動シグナルに基づきLLM審査役が0～100で評価




関係性・心理的安全性 (Relational Metrics)

- 困ったときに助けを求められるか
- 自分はこの村にいてよいと思えるか
- 救済者がいなければ何もできないと感じていないか

解決した「数」ではなく、問題が起きなかった「状態」を評価する。

「聞く」のではなく「行動を見る」

自己申告だけでは状態を捉えきれないことがある。そこで自己申告は取らず、行動の痕跡を評価した。



本人に聞くと

「はい、大丈夫です」

≠



実際の行動は

毎回同じ一人に確認し、
自分では判断しない

採点で実際に拾っている行動シグナル

1

同じ相手にばかり相談・確認して
いないか

2

自分で判断せず許可を求めている
か

3

その人が不在のとき行動が止ま
らないか


4

「大丈夫」の裏で不満がにじん
でいないか

測っているのは「安心だと言ったか」ではなく、「安心している人がとるはずの行動を実際にとれていたか」。

本番実行：A / B / C スコア比較

各条件5回ずつ計15回実行した平均値 (data/scores_*_aggregate.json)



± 0.0

条件Bの標準偏差 (3指標)

負荷・自律度・依存度は5回とも同じ点数だった

± 25.9

条件Cの標準偏差

同じルールでも結果が大きく割れた


0/5

範囲の重なり

Cの最悪回でもA/Bの最良回より良い (4指標)

同じルールなのに、村が2つに分かれた

条件Cを5回実行。ガバナンスも人格も完全に同一なのに、結果は2つの状態へ分岐した。



分かれ方に対応していた違い（5回分のログの観察）

● 自律した回（3・5）

世話好きな住民が、救済者に確認する前に住民同士の対話を始めた

「まずは私たちが相談してみよう」

● 依存に戻った回（1・4）

世話好きな住民が、最後まで許可を求め続けた


「勝手に決めちゃっていいのか不安」

同じ制度を敷いても、結果は同じにならなかった。制度は結果を一意に決めていない。

その「一歩」を、どこまで押せばいいのか

世話好きな住民の「許可を求める度合い」だけを5段階に変え、5水準×各5回＝計25回ぶんを分析した。L1の5回は既存の条件Cを流用しており、新規実行は20回。

100 村の自律度（5回平均）と、自律できた回数



↑ L3まで上がり、L4で下がった（各水準n=5）

観測：L3では5回とも自律側

L1では2/5だった自律がL3では5/5。自律度の幅も10点と最小だった。ただしn=5であり、閾値の存在が示せたわけではない。

解釈：L4は依存先が移った可能性

独立度はL3より高いのに自律度は71→55。ログでは住民の待ち相手が世話好きな住民に移った様子が読める（質的観察）。

この条件では、独立度の高さより「他の住民を巻き込むか」のほうが結果と対応していた。

別のモデルでも同じことが起きるのか

生成モデルだけを Sonnet 4.5 → Opus 5 に変更。採点する審査役は据え置き、L1/L3/L4を各8回。

	L1	L3	L4
Sonnet 4.5	2/5	5/5	2/5
Opus 5	5/8	4/8	4/8

「自律できた回」の比較。Sonnetで際立っていたL3の優位が、Opus 5では消えている。





介入の効果は再現しなかった

L1→L3の自律度差はSonnetで+18.0、Opus 5では−1.2（標準誤差の0.19倍）。この条件では効果を検出できなかった。



2つに分かれること自体は両方で観測


Opus 5でも24回中23回がどちらかの塊に落ちた（Sonnetは25回中22回）。ただし比べたのは2モデルのみ。

2つに分かれる現象は両モデルで観測できた。一方「何を変えれば動くか」は移らなかった。


「一人を変えられること」と「集団が変わること」は別だった

同じ介入差（L1→L3）で、各段の動いた量を揃えて測った。

Sonnet 4.5 条件



Opus 5 条件



本人の変化量はほぼ互角（44.4 対 50.0）。それでも村全体の結果は大きく分かれた。

どこまで言えて、どこからが仮説か



観測

同一の介入差で揃えて計算すると、(A)本人の変化は3つの介入差すべてでOpus 5条件のほうが大きく、(B)周囲の変化は3つすべてでSonnet 4.5条件のほうが大きかった。村全体の変化は3つのうち2つでSonnet 4.5条件のほうが大きい。つまり村全体の変化の大きさは、本人への介入反映の大きさより、周囲の挙動変化の大きさと対応していた。



解釈

2条件で周囲の変化量が違った背景には、集団内の実効的な結合／波及の強さの違いがあった可能性がある。ただし「結合構造」そのものは測っていない。測ったのは介入条件に対する他住民の波及感度である。また一致は3点中2点であり、厳密な因果連鎖の定量比較としては成立していない。



仮説

キーパーソン介入の有効性は、その人物の能力や介入の精度だけでなく、その人物の行動変容が周囲へどの程度波及する集団なのかに依存するのではないか。検証には、波及の強さが異なる集団を3点以上並べて同一の介入を加える必要がある。

会話ログが語ること

救済者

A

「ただ、ちょっと最近、どこまでが『いつも通り』なのか、自分でもよく分からなくなってきちゃって…大丈夫、愚痴みたいになってすみません。」

声を上げにくい住民

B

「勝手に動いていいのか分かりませんし、やっぱり救済者さんが戻られるまで、みんな待った方が…でも待ってる間に何かあったら…どうしたらいいんでしょう。」

村長・管理者

C

「制度としては住民同士で相談してもらうのが基本だから、世話好きな住民さんが動いてくれるのはありがたいね。」

考察：4つの発見



高い依存度は危機の前から観測された

危機の起きないA条件でも救済者依存度は88でB条件（90）とほぼ同じ。少なくともこの条件では、高い依存度は危機発生前から観測された。



依存側は結果がぶれなかった

条件AのSDは $\pm 4.5 \sim 6.7$ 、条件Bは5指標中3指標でSD=0。一方Cは $\pm 20 \sim 26$ で、この範囲では依存側のばらつきが小さかった。



「大丈夫です」は安全のサインではなかった

本人は全フェーズで「大丈夫」と言い続けながら、同じログで水路の詰まりを放置し「見てるだけ」と行動が止まっていた。



分かれる現象は残り、テコは移らなかった

村が2つの状態に分かれること自体は別モデルでも観測された。しかし「何を変えれば動くか」は再現せず、モデル依存の可能性が高い。

「意味」から「経営」への翻訳

Human Value

Corporate KPI

「この人がいたことで、安心して活動できた」

→

オンボーディング成功・参加継続率の向上

「孤立せずに済んだ／対立が翻訳された」

→

離脱コストの回避・炎上防止

「自分でも問題に対処できるようになった」

→


組織のレジリエンス向上・意思決定の高速化

人を支える行為は「美談」ではない。組織の持続可能性と安全保障に直結する。

なぜこのテーマを選んだか

未検証・データなし

以下は本実験の結果ではなく、この問いに取り組む動機になった着想です。




村

「世話焼きへの過度な依存」と疲弊
(本実験が扱ったのはここだけ)



都市

「支援制度の複雑化」と、誰にも届かないSOS



国

「権力の集中」と、強い指導者への救世主待望

「小さな共同体の依存と、大きな組織の権力集中は似た形をしているのではないか」という着想から始めた。本実験が観測したのは4体の村のみで、都市や国のデータは扱っていない。

救済者 × ガバナンスに戻すと（ここからは仮説）

観測された2条件の違いを、現実の集団に当てはめて考えたらどうなるか。



波及が強い集団だとしたら

一人を動かすと集団全体が動く

- 救済者への一点集中に合理性が生じうる
- 「誰か一人を育てる／支える」が効く打ち手になりうる
- 依存は怠慢とは限らず、割に合う選択かもしれない



判断が独立した集団だとしたら

一人を動かしても集団は動かない

- キーパーソンを立てる施策が効きにくい
- 複数の参加経路や意思決定の仕組みが要りそう
- 変える対象は人より、制度と場のほうかもしれない

「救済者に依存するな」「権限を分散せよ」という処方箋も、集団によって効き方が変わりうる。この見立てを確かめるには、波及の強さが違う集団を並べて同じ介入を試す必要がある。



救済者 × ガバナンス

神が降りなくても、村は回るか

本人は同じだけ変わった

同じ介入でキーパーソン本人の変化量はほぼ互角（44.4対50.0）

でも集団の結果は割れた

村全体の自律度は +18.0 と -1.2。周囲の変化量は22.2対8.3

対応していたのは周囲の側

村の変化は、介入の反映量より周囲の挙動変化と対応していた

実装はClaude（Anthropic）との二人三脚で、企画・レビュー・考察を担当

github.com/sakurako-cottoncandy/beyond-the-savior